

Informe de Análisis Exploratorio de Datos para la Identificación de Oportunidades Comerciales en Seguros

Johnnatan Villaneda Navarro

Curso

Análisis exploratorio de datos en Python - SENA

Docente

Luz Maryuri Gara Alvarez

Julio 2026

Introducción

Objetivo

Aplicar técnicas de análisis exploratorio de datos en Python sobre el dataset DatosSeguros.csv para orientar la toma de decisiones estratégicas y comerciales del negocio de seguros.

Descripción de la Base de Datos

Dataset compuesto con 1333 registros limpios (después de depuración) con variables sociodemográficas (edad, sexo, imc, hijos, fumador, región, rango_edad) y financieras (valor_seguro)

Importamos las librerías necesarias para manipulación y visualización de datos, después importamos el dataset usando pandas para leer el archivo .csv

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

df = pd.read_csv('../Anexos/DatosSeguros.csv')
df.head(5)
```

	edad	sexo	imc	hijos	fumador	region	valor_seguro
0	19	F	27.90	0	yes	Caribe	16884.9240
1	19	F	27.90	0	yes	Caribe	16884.9240
2	19	F	27.90	0	yes	Caribe	16884.9240
3	18	M	33.77	1	no	Cundinamarca	1725.5523
4	28	M	33.00	3	no	Cundinamarca	4449.4620

Antes de continuar procedemos a hacer limpieza de datos buscando datos nulos y duplicados que afectarían los resultados finales

```
df.isnull().sum()

edad          0
sexo          0
imc           2
hijos         0
fumador       2
region        0
valor_seguro  0
dtype: int64
```

Tenemos 2 variables con valores nulos, determine que no afectaran directamente el resultado final ya que no son demasiados datos afectados

```
df.duplicated().sum()

np.int64(12)
```

Ya que no son muchos valores duplicados, revisamos cuales son

```
filas_duplicadas =
df.value_counts(dropna=False).reset_index(name='frecuencia')
filas_duplicadas = filas_duplicadas[filas_duplicadas['frecuencia'] >
1]
filas_duplicadas.head(10)
```

	edad	sexo	imc	hijos	fumador	region	valor_seguro
frecuencia							

0	19	F	27.900	0	yes	Caribe	16884.92400
7							
1	38	M	16.815	2	no	Boyaca	6640.54485
4							
2	19	M	30.590	0	no	Antioquia	1639.56310
2							
3	52	M	34.485	3	yes	Antioquia	60021.39897
2							
4	20	F	21.800	0	yes	Caribe	20167.33603
2							

Podemos observar que 5 datos estan duplicados multiples veces dentro del dataset.

Crear un nuevo dataset

Hacemos una copia limpia del dataset como buena practica para no manipular el data set original eliminando nulos y duplicados

```
df_clean = df.dropna().drop_duplicates().copy()
df_clean.info()
```

```
<class 'pandas.DataFrame'>
Index: 1333 entries, 0 to 1347
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype
---  -
0   edad            1333 non-null   int64
1   sexo            1333 non-null   str
2   imc             1333 non-null   float64
3   hijos           1333 non-null   int64
4   fumador         1333 non-null   str
5   region          1333 non-null   str
6   valor_seguro    1333 non-null   float64
dtypes: float64(2), int64(2), str(3)
memory usage: 83.3 KB
```

Vamos a separar por rango los datos para reducir el ruido y darle manejo a cualquier dato atipico que pueda tener, para esto haremos un rango por edades, usando .describe podemos hcer un resumen estadistico sencillo y tambien podemos observar cuales son las edades minimas y maximas del dataset

```
df_clean.describe()
```

	edad	imc	hijos	valor_seguro
count	1333.000000	1333.000000	1333.000000	1333.000000
mean	39.195049	30.652097	1.092273	13261.908454
std	14.052008	6.097609	1.205484	12093.507648
min	18.000000	15.960000	0.000000	1121.873900
25%	27.000000	26.220000	0.000000	4738.268200

50%	39.000000	30.360000	1.000000	9377.904700
75%	51.000000	34.675000	2.000000	16657.717450
max	64.000000	53.130000	5.000000	63770.428010

```
rangos = [17, 25, 35, 45, 55, 65]
nombre_rangos = ['18-24', '25-34', '35-44', '45-54', '55+']
```

```
# Nueva variable
```

```
df_clean['rango_edad'] = pd.cut(df_clean['edad'], bins=rangos,
labels=nombre_rangos)
df_clean.head(5)
```

	edad	sexo	imc	hijos	fumador	region	valor_seguro
rango_edad							
0	19	F	27.900	0	yes	Caribe	16884.92400
18-24							
3	18	M	33.770	1	no	Cundinamarca	1725.55230
18-24							
4	28	M	33.000	3	no	Cundinamarca	4449.46200
25-34							
5	33	M	22.705	0	no	Antioquia	21984.47061
25-34							
6	32	M	28.880	0	no	Antioquia	3866.85520
25-34							

Análisis Estadístico y Visualización de Datos


Vamos a responder las preguntas iniciales

1. ¿Las personas fumadoras representan el mayor potencial para venta de seguros?

```
# Diferencia entre fumadores y no fumadores
total_fumador = df_clean['fumador'].value_counts() * 100
labels = df_clean['fumador'].value_counts().index
colors = sns.color_palette('Set2')[0:2]

plt.title('Diferencia Total de Fumadores')
plt.pie(total_fumador, labels=labels, colors=colors, autopct='%1.1f%%')
plt.show()
```

Diferencia Total de Fumadores




```
# Diferencia en el valor de seguro entre fumadores y no fumadores
res_valor_seguro =
df_clean['valor_seguro'].groupby(df_clean['fumador']).sum()
labels = df_clean['fumador'].value_counts().index
colors = sns.color_palette('Paired')[0:2]

print(f"{res_valor_seguro.map('${:,.2f}'.format)}")

plt.title('Diferencia Valor de Seguro por Condición de Fumador')
plt.pie(res_valor_seguro, labels=labels, colors=colors, autopct='%1.1f%%')
plt.show()

fumador
no      $8,942,511.57
yes     $8,735,612.40
Name: valor_seguro, dtype: str
```

Diferencia Valor de Seguro por Condición de Fumador




```
# Agrupamiento descripcion por condicion de fumador
res_fumador = (
    df_clean.groupby('fumador')['valor_seguro']
    .agg(['count', 'mean', 'median', 'sum'])
    .reset_index()
)

formatos = {"mean": "${:,.2f}".format, "median": "${:,.2f}".format,
"sum": "${:,.2f}".format}
print(res_fumador.to_string(formatteratters=formatos, index=False))

# Grafico Barplot
sns.barplot(
    data=df_clean, x='fumador', y='valor_seguro', estimator=sum
)
plt.title('Ingreso Total de Seguros por Condición de Fumador')
plt.ylabel('Ingreso Total (USD)')
plt.show()
```

fumador	count	mean	median	sum
no	1060	\$8,436.33	\$7,345.41	\$8,942,511.57
yes	273	\$31,998.58	\$34,439.86	\$8,735,612.40



Respuesta

Si, en términos de valor individual e ingreso por cliente, pero se debe considerar el volumen poblacional

Fumadores

- Si fumadores: Representan el 20.5% de la población (273 personas), estos generan casi la mitad de los ingresos totales (\$8,735,612 USD / 49.35%)
- No fumadores: Son el 79.5% de los clientes (1062 personas) y generan un 50.6% (\$8,965,156)

Conclusion

Las personas fumadoras representan el ingreso promedio mas alto. Sin embargo, comercialmente la estrategia ideal es mixta: captar fumadores para alta rentabilidad por cliente y no fumadores para asegurar volumen e ingresos sostenidos a un bajo nivel de riesgo.

2. ¿Cual es la edad poblacional en la que se debe concentrar la estrategia comercial teniendo en cuenta el mayor ingreso?

```
# Agrupamiento por rango de edad
res_rango_edad = df_clean.groupby('rango_edad')['valor_seguro'].sum()
labels = res_rango_edad.index
```



```

colors = sns.color_palette('Paired')[0:len(labels)]


print(f"{res_rango_edad.map("${:,.2f}".format)}")

# Gráfico Ingreso por Valor de Seguro según Rango de Edad
plt.title('Distribución del Ingreso por Valor de Seguro segun Rango de Edad')
plt.pie(res_rango_edad, labels=labels, colors=colors, autopct='%1.1f%%')
plt.show()

rango_edad
18-24    $2,778,987.27
25-34    $2,812,703.70
35-44    $3,555,014.40
45-54    $4,484,412.72
55+      $4,047,005.87
Name: valor_seguro, dtype: str

```

Distribución del Ingreso por Valor de Seguro segun Rango de Edad



```

# Agrupamiento por rango de edad
res_edad = (
    df_clean.groupby('rango_edad')['valor_seguro']
    .agg(['count', 'mean', 'sum'])
    .reset_index()
)

```

```

formatos = {"mean": "${:,.2f}".format, "sum": "${:,.2f}".format}
print(res_edad.to_string(formatters=formatos, index=False))

```

```

# Gráfico de Barras por Rango de Edad


```

```

plt.figure(figsize=(6, 4))
sns.barplot(
    data=res_edad,
    x='rango_edad',
    y='sum',
    palette='Blues_d',
    hue='rango_edad',
    legend=False,
)
plt.title('Ingresos Totales por Rango Poblacional de Edad')
plt.ylabel('Ingresos Totales')
plt.show()

```

rango_edad	count	mean	sum
18-24	305	\$9,111.43	\$2,778,987.27
25-34	268	\$10,495.16	\$2,812,703.70
35-44	263	\$13,517.17	\$3,555,014.40
45-54	282	\$15,902.17	\$4,484,412.72
55+	215	\$18,823.28	\$4,047,005.87



Respuesta

La estrategia comercial debe concentrarse en el rango de 45 a 54 años (seguido muy de cerca por el rango de 55+ años)

- Rango 45-54 años: Es el líder en generación de ingresos con \$4,484,412.72 (25.4% del ingreso total del negocio)
- Rango 55+ años: Genera \$4,047,005.87 (22.9% del ingreso total) con el promedio unitario más alto de todos los grupos (\$18,513.28)

Conclusion

Los grupos mayores de 45 años representan casi el 50% del ingreso total. Las personas mas jovenes generan un promedio mucho mas bajo, por lo que enfocar presupuesto comercial en adultos de 45 a 54 años maximizara el retorno del valor recaudado por seguro


3. ¿Cuál es la región con mayor potencial de venta de seguros teniendo en cuenta los ingresos?

```
# Agrupamiento por region
res_region = (
    df_clean.groupby('region')['valor_seguro']
    .agg(['count', 'mean', 'sum'])
    .reset_index()
)

formatos = {"mean": "${:,.2f}".format, "sum": "${:,.2f}".format}
print(res_region.to_string(formatters=formatos, index=False))

# Gráfico de Ingresos por Region
plt.figure(figsize=(8, 4))
sns.barplot(
    data=res_region,
    x='region',
    y='sum',
    palette='Set2',
    hue='region',
    legend=False,
)
plt.title('Ingresos Totales Recaudados por Región')
plt.ylabel('Ingresos Totales')
plt.show()
```

	region	count	mean	sum
	Antioquia	323	\$12,466.89	\$4,026,806.73
	Boyaca	323	\$13,417.81	\$4,333,952.74
	Caribe	325	\$12,346.94	\$4,012,754.65
	Cundinamarca	362	\$14,653.62	\$5,304,609.85



Respuesta

La region con mayor potencial de venta es Cundinamarca

- Cundinamarca: Ocupa el primer lugar absoluto en ingresos con \$5,304,609.85 (representa el 30.01% de las ventas totales). Además, cuenta con el mayor número de clientes registrados (362) y el promedio de recargo/seguro más alto (\$14,653.62).
- Comparativa: Boyacá ocupa el segundo lugar con \$4,333,952.74 (24.51%), Antioquia el tercero con \$4,026,806.73 (22.78%), y el Caribe el cuarto con \$4,012,754.65 (22.7%)

Conclusion

Cundinamarca combina la mayor concentración de clientes con las primas promedio más elevadas, consolidándose como la región estratégica prioritaria

Conclusiones y Recomendaciones Comerciales

1. **Campañas Focalizadas en Cundinamarca:** Asignar mayor presupuesto de marketing en la región de Cundinamarca por representar el 30.01% de los ingresos.
2. **Segmentación para Personas de 45 a 54 años:** Diseñar productos de cobertura integral orientados a este rango, ya que genera el mayor volumen de ingreso total (\$4.48M).
3. **Estrategia Diferenciada de Fumadores:** Crear un paquete de seguros especializado/premium para personas fumadoras que capte la alta disposición/valor de cobro unitario (\$31,998 USD promedio).